

主动验证：提高二阶段去偏效率的策略抽样

2026 年 6 月 30 日

摘要

本文考虑一个使用机器学习生成变量进行二阶段回归的问题。第一阶段使用机器学习预测某个我们感兴趣的变量，并在第二阶段将其作为解释变量纳入回归。然而，机器学习预测误差可能导致估计量产生偏误。在矩估计框架下，我开发了一种缓解该问题的新方法。相较于既有方法，它不仅更稳定、成本低而且易于推广。由于该方法的使用条件是研究者拥有额外的验证预算，为此我进一步考察了存在预算约束的情况下，如何利用机器学习模型识别哪些数据点最值得验证，即主动验证，从而节省实施成本。即使在验证预算十分紧张的情境下，该方法在现实数据集上的表现效果依旧极其惊人。它可以节省 40% 以上的验证样本量并缩短近四分之一的置信区间宽度。

关键词：机器学习；预测误差；主动验证；推断效率

1 引言

近年来，使用机器学习提取非结构变量的方法被越来越广泛地用于经济学、管理学、营销学和信息系统等领域的实证研究。这类研究通常具有两阶段结构：在第一阶段，研究者使用少量人工标注数据训练机器学习模型，并将其应用于更大规模的未标注样本，从而得到机器学习生成变量 $\hat{X}_i$ 。在第二阶段，研究者将 $\hat{X}_i$ 作为真实变量 X_i 的替代放入回归模型中，估计其与结果变量 Y_i 之间的关系。由于人工标注全部样本往往成本高昂，这种通过少量人工标签获得全样本标签的做法在实际研究中具有很强吸引力。

然而，这一做法也引入了一个新的问题：机器学习生成变量通常包含预测误差，而这些误差并不一定等同于经典测量误差。在经典设定中，误差常被假定为与真实变量和结果方程误差项相互独立的随机噪声，但机器学习预测误差往往具有系统性。例如，模型可能在某些文本更复杂、图像质量更低、样本群体更少见或特征更模糊的观测上更容易出错。如果这些样本特征同时影响结果变量，那么预测误差就会与第二阶段回归中的误差项相关，从而使直接使用 $\hat{X}_i$ 的朴素回归产生系统性偏误。

现有研究已经开发了众多方法修正机器学习预测误差所带来的估计偏误，其中一支主流文献发展了使用验证数据的校正方法。其基本思路是在一个较小的验证样本中同时观测真实结果变量和机器学习生成的代理变量，并利用验证样本所揭示的真实结果变量相对于代理变量及其他可观测信息的条件分布或条件矩来校正主样本中的估计偏差。与仅使用验证样本所得到的估计量相比，这类方法能够结合主样本中样本量优势，从而提高估计效率。然而，现有方法仍存在若干局限。第一，一些方法依赖较强的假设，例如要求非结构化数据中的外围特征不直接影响结果变量，或要求机器学习生成变量的误差结构满足特定条件。但在许多实证应用中，机器学习模型往往会利用大量非焦点特征以提高预测准确率，而这些特征本身也可能直接影响结果变量，从而使相关假设难以满足。第二，更一般的校正方法虽然可以放松部分假设，但面临处理连续标签问题时实施成本高昂，或者在实际数据中估计量不稳定等困境。

如何在充分利用主样本中大规模代理变量信息的同时以较低的验证成本实现可靠的统计推断，是我们关注的核心问题。为此，本文提出一种名为“主动验证”的方法。该方法首先利用全样本中可观测的机器学习生成变量构造代理矩条件，随后通过少量验证样本观测真实变量，对真实矩条件与代理矩条件之间的差异进行逆概率加权校正。在适当的抽样设计和正则条件下，该校正矩能够恢复目标矩条件，从而修正机器学习预测误差所导致的估计偏误。

进一步地，本文借鉴主动统计推断的思想，在给定验证预算的情况下依据验证前可观测信息优先识别那些更可能改变矩条件、并对目标参数估计产生较大影响的观测。与均匀验证相比，该方法能够大幅提高估计精度，即在相同的验证预算下获得更小的渐近方差和更短的置信区间。从实践角度考虑，该做法可以大幅降低纠偏成本。

本文主要从以下三个方面为既有研究做出贡献。第一，本文提出一种易于实施的矩校正方法，用于修正机器学习预测误差进入回归模型后所导致的估计偏误。我们的方法并不需要严苛的假设，只需通过真实矩条件与代理矩条件之间的差异即可进行修正，并且能够充分利用主样本中的大规模代理变量信息。第二，本文强调验证样本的选择策略。当矩污染在样本之间存在异质性时，和均匀验证相比，我们所提出的方法可以提高估计精度从而节约预算成本。第三，我将主动统计推断的思想应用到矩估计框架下的纠偏问题上，进而拓展了该方法的使用范围。

本文余下部分安排如下。第二节介绍相关文献。第三节建立统一矩条件校正框架，给出校正估计量一致性与渐近正态性证明。第四节推导给定验证预算下的最优验证概率。第五节分别讨论主动验证在普通最小二乘、工具变量、双重差分和断点回归中的具体应用。第六节使用现实数据验证本文方法的有效性。

2 文献

本文首先与测量误差文献相关。测量误差通常指研究者观测到的变量与其真实值之间存在偏差。在经典测量误差框架下，测量误差通常被假定为与真实变量及回归方程

误差项独立。在这种情形中,若带误差的变量作为解释变量进入线性回归,普通最小二乘估计量通常会出现向零收缩的衰减偏误。更一般的非经典测量误差允许测量误差与真实变量或其他协变量相关,因此偏误不再是简单的衰减形式。已有文献对测量误差模型及其校正方法进行了系统研究,相关综述可参见 (Fuller, 2009)、(Chen et al., 2011) 和 (Schennach, 2016)。机器学习生成变量引入的二阶段偏误,本质上属于非经典测量误差,因为除非机器学习模型达到 100% 的预测精度,否则即使算法收敛到最优预测函数,也无法保证使用预测出的变量代替真实解释变量进行回归时,回归方程误差项满足条件期望为零的假设。

针对机器学习预测误差导致的估计偏误问题,一个重要的缓解思路是利用辅助数据(或验证样本)校正机器学习生成变量中的测量误差。在这类设定中,研究者通常在主样本中只能观测到机器学习生成的代理变量,而在一个较小的验证样本中同时观测到代理变量及其真实值。由此,辅助样本提供了关于真实变量与代理变量之间关系的信息,从而校正估计偏误。相较于仅使用验证样本进行估计,这类方法能够利用主样本中的大量观测信息,因此具有显著的样本量优势。

已有少数开创性研究专门讨论使用机器学习预测变量作为真实变量替代所导致的估计偏误。(Yang et al., 2018)、(Fong & Tyler, 2020) 以及 (Qiao & Huang, 2021) 分别在不同模型设定下提出了相应的偏误校正方法。然而,这些方法通常依赖较强的识别假设,例如“外围特征无影响”假设,即非结构化数据只通过研究者关注的焦点特征影响结果变量,而其他被机器学习模型利用的外围特征不会直接影响结果变量。该假设在许多实际应用中可能较难满足,因为机器学习模型往往会利用背景颜色、文本风格、图像质量、共现物体等非焦点信息来提高预测准确率,这些外围特征本身也可能对结果变量产生直接影响。

为放松“外围特征无影响”假设,近期研究开始关注更一般的非经典测量误差情形,即允许机器学习预测误差与回归方程中的误差项相关。这一问题也与使用辅助数据矫正测量误差的文献密切相关,代表作为 (Chen et al., 2005)。该文章允许测量误差与真实变量之间存在任意相关性,但它通常依赖一个关键的可迁移性条件:给定代理变量后,真实变量的条件分布在主样本和辅助样本中相同。若辅助样本来自不同数据环境、标注规则或样本选择机制,则这一条件可能难以满足,从而影响校正估计量的一致性。近期的两篇文章进一步发展了这一方法:(Wei & Malik, 2026) 训练 $q(w_i | \hat{w}_i, x_i, y_i)$, 并在 MLE 函数中对潜在真实标签 w_i 按照条件概率加权来近似 oracle 估计准则,从而在不施加“外围特征无影响”假设的情况下修正偏误。然而,当 w_i 为连续取值时,实现成本会变得高昂。(Allon et al., 2023) 则将 (Chen et al., 2005) 的方法推广到更多的模型设定中,但在现实数据中矫正的估计量表现并不稳定。

受上述研究启发,本文基于使用辅助数据校正预测误差导致的估计偏误思想,提出一种新的矩校正方法,这种方法无需可迁移假设、更易实施并且在现实数据中表现稳定。

除了开发新的纠偏方法外,我们还设计了最优验证概率从而提高验证预算使用效

率，而这一问题在上述文献中并未涉及。我们关注验证样本效率的原因有二：其一是本文方法需要有一定的额外验证预算才可以使用；其二是无论从既有研究还是从本文现实数据模拟来看，所提出的方法随着验证预算增加，矫正方法表现才会有突飞猛进的增长。因此，研究者自然会关心：能否通过更有效的样本选择机制，在较低验证预算下获得优于均匀验证的估计表现？

基于这一动机，本文借鉴了主动统计推断文献的思想 [10]。其基本直觉是：验证资源应优先分配给那些预测不确定性较高的观测；对于模型预测较为可靠的样本，则可以完全利用预测信息。通过这种方式，主动统计推断方法能够在较少真实标签下获得接近大规模标注数据的推断精度。然而，既有主动统计推断文献主要建立在凸 M-估计框架下，关注的是结果变量 Y_i 缺失时如何设计验证概率以降低估计量方差。本文与之区别在于：第一，和既有统计推断所关注的问题不同，我们关注缺少 X_i 的情况下，如何使用 $\hat{X}_i$ 构造矫正统计量恢复一致性以及应该验证哪些 X_i 从而使矫正估计量方差更小。第二，本文不仅局限于 M-估计，而是从矩条件出发构造统一的主动验证校正框架。这样一来，本文的方法不仅覆盖 OLS 等可以写成 M-估计的问题，也能够处理 IV、GMM、DiD、RD 等更广泛的计量经济学识别设计。由此，本文将主动统计推断的思想拓展到使用机器学习预测变量作为解释变量情形下的回归纠偏问题。

3 统一矩条件校正框架

本节给出方法的一般理论框架。我们使用 OLS 问题介绍本文方法的直觉，随后将其推广至矩框架，进而证明“主动验证”具备的良好统计学性质。

3.1 从一个例子开始

考虑一个一元线性回归模型，为了更清楚地看到偏误从何而来，我们暂时忽略截距项，或者等价地，把 Y_i 和 X_i 都理解为剔除了截距后的中心化变量。于是模型可以简化写成

$$Y_i = \beta_1 X_i + \varepsilon_i,$$

并且真实变量 X_i 对应的 oracle 矩条件为

$$E[X_i(Y_i - \beta_1 X_i)] = 0.$$

现在假设我们无法观测真实的 X_i ，只能观测机器学习模型生成的预测变量 $\hat{X}_i$ 。令预测误差为 $e_i = \hat{X}_i - X_i$ ，如果我们直接用 $\hat{X}_i$ 替代 X_i ，那么朴素估计量实际求解的是

$$E[\hat{X}_i(Y_i - \beta_1 \hat{X}_i)] = 0.$$

为了理解这个矩条件为什么通常不再成立，可以把真实模型 $Y_i = \beta_1 X_i + \varepsilon_i$ 代入其中，

得到

$$\begin{aligned} E \left[\hat{X}_i(Y_i - \beta_1 \hat{X}_i) \right] &= E \left[(X_i + e_i) \{Y_i - \beta_1(X_i + e_i)\} \right] \\ &= E \left[(X_i + e_i)(\varepsilon_i - \beta_1 e_i) \right] \\ &= E[X_i \varepsilon_i] + E[e_i \varepsilon_i] - \beta_1 E[X_i e_i] - \beta_1 E[e_i^2]. \end{aligned}$$

由于 oracle 矩条件保证 $E[X_i \varepsilon_i] = 0$ ，所以上式变成

$$E \left[\hat{X}_i(Y_i - \beta_1 \hat{X}_i) \right] = E[e_i \varepsilon_i] - \beta_1 E[X_i e_i] - \beta_1 E[e_i^2].$$

这个表达式清楚地说明了朴素估计量偏误的来源。即使预测误差 e_i 与真实解释变量 X_i 和误差项 ε_i 都不相关，即 $E[e_i \varepsilon_i] = 0$ 且 $E[X_i e_i] = 0$ ，最后一项 $-\beta_1 E[e_i^2]$ 仍然一般不为零。也就是说，只要机器学习预测变量 $\hat{X}_i$ 中含有预测误差，朴素矩条件在真实参数处通常就不再等于零。

在最经典的情形下，如果 e_i 是均值为零、且与 X_i 和 ε_i 都不相关的预测误差，那么朴素回归的总体斜率可以写成

$$\beta_1^{naive} = \frac{E[\hat{X}_i Y_i]}{E[\hat{X}_i^2]} = \frac{\beta_1 E[X_i^2]}{E[X_i^2] + E[e_i^2]}.$$

由于 $E[X_i^2] + E[e_i^2] > E[X_i^2]$ ，即分子中真正有用的协方差信号主要来自 X_i ，但分母中却额外加入了预测误差 e_i 带来的无效波动，因此系数会向零收缩。然而，如果解释变量是由机器学习生成的，预测误差 e_i 未必与 X_i 或 ε_i 独立。例如，机器学习模型可能在某些类型的样本上系统性高估或低估 X_i ，也可能在结果变量 Y_i 较高或较低的样本附近表现得更差。此时， $E[e_i \varepsilon_i]$ 和 $E[X_i e_i]$ 不为零，估计量的偏误方向就是任意的。

这个简单例子说明了本文方法的基本出发点：估计量是否出现偏误取决于使用 $\hat{X}_i$ 后，矩条件是否仍然成立。因此，我们真正应该关心机器学习预测误差对矩条件造成的污染：

$$d_i^{OLS}(\beta) = X_i(Y_i - \beta X_i) - \hat{X}_i(Y_i - \beta \hat{X}_i).$$

如果我们能够观察到所有 X_i ，那么每个样本的矩污染就可以观测，此时很容易对估计进行矫正。但 X_i 的验证往往成本很高，因此我们无法获得所有 X_i 的真实值。一个自然的想法是：只验证一部分样本，并利用这部分样本来校正机器学习生成变量带来的矩条件污染。具体来说，令 $\xi_i \in \{0, 1\}$ 表示样本 i 是否被验证， $\pi_i = P(\xi_i = 1)$ 表示其验证概率，构造如下校正矩条件：

$$g_i^{AI}(\beta) = \hat{X}_i(Y_i - \beta \hat{X}_i) + \frac{\xi_i}{\pi_i} \left[X_i(Y_i - \beta X_i) - \hat{X}_i(Y_i - \beta \hat{X}_i) \right].$$

这个式子的直觉是：第一项使用所有样本的朴素矩条件；第二项只在被验证样本上出现，通过计算真实矩条件和朴素矩条件之间的差异来弥补机器学习变量造成的矩条件污染。由于被验证样本只是一部分，所以需要乘以逆概率权重 $1/\pi_i$ ，使得这些被验证样本能够代表它们所对应的总体样本。容易证明 $E[g_i(\theta_0; X_i)] = E[g_i^{AI}(\theta_0)]$ ，详细证明过程请见 3.2 节。

并不是所有样本的验证价值都一样，究竟该如何选择 π_i 呢？“好”的 π_i 可以提高预算的使用效率，从而在相同的验证集预算下获得更高效（方差或置信区间更小）的估计（详细证明见 3.4 和 4.2 节）。一个简单的直觉是我们应以更大的概率对矩污染更大的点标注 X_i ，这就要求 π_i 能反映特征为 X_i 的点对于矩条件的污染程度， π_i 很大就说明特征为 X_i 的点对于矩条件的污染会很大； π_i 很小则说明特征为 X_i 的点对于矩条件的污染会很小。关于 π_i 的选择将在 4.1 节中详细讨论。

3.2 矫正矩条件无偏性

接下来，我们将 3.1 节的直觉拓展到更一般的矩框架下，并进行正式的证明。令

$$\xi_i = \begin{cases} 1, & \text{样本 } i \text{ 被验证, 真实 } X_i \text{ 被观测到} \\ 0, & \text{样本 } i \text{ 未被验证} \end{cases}$$

$\xi_i \sim \text{Bern}(\pi(\hat{X}_i))$ 。验证概率为 $P(\xi_i = 1 \mid \hat{X}_i) = \pi_i$, $0 < \pi_i \leq 1$ ，表示给定协变量预测值后该观测被验证的概率。定义真实矩函数和机器学习近似矩函数分别为 $g_i(\theta; X_i)$ 和 $g_i(\theta; \hat{X}_i)$ 。二者之间的差异为 $d_i(\theta) = g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)$ ，表示机器学习生成变量对矩条件造成的污染。由于 X_i 只有在验证样本中才能观测到，所以 $d_i(\theta)$ 只有在 $\xi_i = 1$ 时可计算。本文构造如下校正矩函数：

$$g_i^{AI}(\theta) = g_i(\theta; \hat{X}_i) + \frac{\xi_i}{\pi_i} [g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)].$$

等价地，

$$g_i^{AI}(\theta) = g_i(\theta; X_i) + (1 - \frac{\xi_i}{\pi_i})d_i(\theta).$$

或者

$$g_i^{AI}(\theta) = g_i(\theta; \hat{X}_i) + \frac{\xi_i}{\pi_i}d_i(\theta).$$

这个矫正函数本质上是利用被验证样本中的真实矩与代理矩之差进行逆概率加权修正。由于验证概率为 π_i ，所以每一个被验证样本代表了大约 $1/\pi_i$ 个同类样本的矩污染信息。不难证明，这一矫正矩函数具有无偏性。

命题 1：校正矩条件的无偏性。假设验证决策满足 $P(\xi_i = 1 \mid \hat{X}_i) = \pi_i$, $0 < \pi_i \leq 1$ 。则对任意 θ ，有

$$E[g_i^{AI}(\theta)] = E[g_i(\theta; X_i)]$$

此时，如果真实参数 θ_0 满足 $E[g_i(\theta_0; X_i)] = 0$ ，则校正矩条件也满足 $E[g_i^{AI}(\theta_0)] = 0$

证明。由定义可得 $g_i^{AI}(\theta) = g_i(\theta; \hat{X}_i) + \frac{\xi_i}{\pi_i} [g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)]$ 。其中，验证概率设定为仅依赖于主要解释变量机器学习预测值 $\hat{X}_i$ ，即 $\pi_i = \pi(\hat{X}_i)$ 。给定 $(X_i, \hat{X}_i)$ 后， $g_i(\theta; X_i)$ 、 $g_i(\theta; \hat{X}_i)$ 和 π_i 都是固定的，可以推出 $E \left[\frac{\xi_i}{\pi_i} \{g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)\} \mid X_i, \hat{X}_i \right] = \frac{g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)}{\pi_i} E[\xi_i \mid X_i, \hat{X}_i]$ 。由于验证概率只依赖于 $\hat{X}_i$ ，并且 $E[\xi_i \mid X_i, \hat{X}_i] = E[\xi_i \mid \hat{X}_i] = \pi_i$ ，所以 $E \left[\frac{\xi_i}{\pi_i} \{g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)\} \mid X_i, \hat{X}_i \right] = g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)$ 。因此，

$E[g_i^{AI}(\theta) \mid X_i, \hat{X}_i] = g_i(\theta; \hat{X}_i) + g_i(\theta; X_i) - g_i(\theta; \hat{X}_i) = g_i(\theta; X_i)$ 。进一步取无条件期望, 得到 $E[g_i^{AI}(\theta)] = E[g_i(\theta; X_i)]$ 。当 $\theta = \theta_0$ 时, 由真实矩条件 $E[g_i(\theta_0; X_i)] = 0$ 可得 $E[g_i^{AI}(\theta_0)] = 0$ 。证毕。

在实际应用中, 验证概率通常并不只依赖于 $\hat{X}_i$, 而是可以依赖于一个更丰富的、验证前可观测的信息集 A_i 。因此, 我们可以将验证概率写为 $\pi_i = \pi(A_i)$, 但这并不会改变证明的主要结构。

3.3 校正 GMM 估计量的一致性和渐进正态性

基于校正矩函数, 定义样本矩: $\hat{m}_n^{AI}(\theta) = \frac{1}{n} \sum_{i=1}^n g_i^{AI}(\theta)$ 。给定一个正定权重矩阵 W_n , 定义校正 GMM 估计量:

$$\hat{\theta}^{AI} = \arg \min_{\theta \in \Theta} \hat{m}_n^{AI}(\theta)' W_n \hat{m}_n^{AI}(\theta).$$

对应的总体目标函数为

$$Q^{AI}(\theta) = m^{AI}(\theta)' W m^{AI}(\theta),$$

由于命题 1 表明 $m(\theta) = E[g_i(\theta; X_i)] = E[g_i^{AI}(\theta)] = m^{AI}(\theta)$, 因此 $Q^{AI}(\theta) = m^{AI}(\theta)' W m^{AI}(\theta) = m(\theta)' W m(\theta) = Q(\theta)$, 即校正 GMM 的总体目标函数与使用真实 X_i 时的 GMM 总体目标函数一致。

在满足以下四个假设前提下, 我们可以证明校正 GMM 估计量的一致性。

假设 1: 存在唯一的 $\theta_0 \in \Theta$, 使得 $E[g_i(\theta_0; X_i)] = 0$ 。并且对任意 $\epsilon > 0$, 有 $\inf_{\|\theta - \theta_0\| > \epsilon} m(\theta)' W m(\theta) > 0$ 。

假设 2: 验证指示变量满足 $P(\xi_i = 1 \mid \hat{X}_i) = \pi_i$, 且存在一个可能随样本量变化的下界 $\underline{\pi}_n > 0$, 使得 $\pi_i \geq \underline{\pi}_n > 0$ 。同时验证样本数量满足 $n_b = \sum_{i=1}^n E[\xi_i] \rightarrow \infty$ 。该假设允许 $n_b/n \rightarrow 0$, 即验证样本比例可以趋于零, 但验证样本数量本身必须趋于无穷。

假设 3: 校正矩函数满足一致大数定律: $\sup_{\theta \in \Theta} \|\hat{m}_n^{AI}(\theta) - m(\theta)\| \xrightarrow{p} 0$ 。一个充分条件是: $g_i^{AI}(\theta)$ 在 θ 上连续, 存在可积包络函数控制其大小, 并且 IPW 权重不过度爆炸, 即 $E[\sup_{\theta \in \Theta} \|(\xi_i/\pi_i)\{g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)\}\|] < \infty$, 或满足相应的三角阵列大数定律条件。

假设 4: $W_n \xrightarrow{p} W$, 其中 W 是正定矩阵。

定理 1: 校正 GMM 估计量的一致性。

在假设 1-4 下,

$$\hat{\theta}^{AI} \xrightarrow{p} \theta_0.$$

证明。 由假设 3, $\sup_{\theta \in \Theta} \|\hat{m}_n^{AI}(\theta) - m(\theta)\| \xrightarrow{p} 0$ 。又由假设 4, $W_n \xrightarrow{p} W$ 。因此样本目标函数 $\hat{Q}_n^{AI}(\theta) = \hat{m}_n^{AI}(\theta)' W_n \hat{m}_n^{AI}(\theta)$ 一致收敛到总体目标函数 $Q(\theta) = m(\theta)' W m(\theta)$, 即 $\sup_{\theta \in \Theta} |\hat{Q}_n^{AI}(\theta) - Q(\theta)| \xrightarrow{p} 0$ 。根据识别条件, $Q(\theta)$ 在 θ_0 处有唯一最小值。容易得到 $\hat{\theta}^{AI} \xrightarrow{p} \theta_0$, 证毕。

下面给出渐近正态性的证明。令 $G = \frac{\partial m(\theta)}{\partial \theta'} \Big|_{\theta=\theta_0} = E \left[\frac{\partial g_i(\theta; X_i)}{\partial \theta'} \Big|_{\theta=\theta_0} \right]$ 。由于校正矩条件满足 $E[g_i^{AI}(\theta)] = E[g_i(\theta; X_i)]$, 因此在适当正则条件下, 其导数也满足 $E \left[\frac{\partial g_i^{AI}(\theta)}{\partial \theta'} \Big|_{\theta=\theta_0} \right] = G$ 。

定义校正矩函数在真实参数处的方差矩阵:

$$\Omega^{AI} = \text{Var}(g_i^{AI}(\theta_0))$$

根据此前定义, $g_i^{AI}(\theta_0) = g_i(\theta_0; \hat{X}_i) + \frac{\xi_i}{\pi_i} [g_i(\theta_0; X_i) - g_i(\theta_0; \hat{X}_i)]$, 也可以写成

$$g_i^{AI}(\theta_0) = g_i(\theta_0; X_i) + \left(\frac{\xi_i}{\pi_i} - 1 \right) d_i(\theta_0)$$

这表明校正矩函数由两部分组成: 第一部分是使用真实 X_i 时的理想矩函数, 第二部分是由于只验证部分样本而产生的 IPW 抽样噪声。在条件独立抽样下, 额外方差项大致为

$$E \left[d_i(\theta_0) d_i(\theta_0)' \left(\frac{1}{\pi_i} - 1 \right) \right].$$

因此

$$\Omega^{AI} = \text{Var}(g_i(\theta_0; X_i)) + E \left[d_i(\theta_0) d_i(\theta_0)' \left(\frac{1}{\pi_i} - 1 \right) \right] + \text{cross terms},$$

其中交叉项 (cross terms) 在若干常见条件下为零, 例如验证抽样独立于结构误差且校正误差条件均值为零时。即使交叉项不为零, 也可以直接用校正矩函数的样本协方差矩阵估计 $\hat{\Omega}^{AI}$, 随后将 $\hat{\Omega}^{AI}$ 代入 sandwich 型方差公式, 可以得到 $\hat{\theta}^{AI}$ 的渐近方差估计量。

假设 5: 局部光滑性。 在 θ_0 的一个邻域内, $g_i^{AI}(\theta)$ 对 θ 可微, 并且

$$\sup_{\theta \in \mathcal{N}(\theta_0)} \left\| \frac{\partial g_i^{AI}(\theta)}{\partial \theta'} \right\|$$

满足适当的可积性条件。同时 $G'WG$ 非奇异。

假设 6: 中心极限定理。 校正矩函数满足

$$\sqrt{n} \hat{m}_n^{AI}(\theta_0) = \frac{1}{\sqrt{n}} \sum_{i=1}^n g_i^{AI}(\theta_0) \xrightarrow{d} N(0, \Omega^{AI}).$$

当 $\pi_i \asymp n_b/n$ 且 $n_b/n \rightarrow 0$ 时, IPW 项可能主导方差, 此时自然的有效收敛速度通常是 $\sqrt{n_b}$ 。在这种情况下, 可以等价地写成

$$\sqrt{n_b} \hat{m}_n^{AI}(\theta_0) \xrightarrow{d} N(0, \Omega_b^{AI}),$$

其中 Ω_b^{AI} 是按验证样本有效规模重新标准化后的方差矩阵。为统一表示, 下文使用 $\sqrt{n}$ 形式, 并允许 Ω^{AI} 随 n 的验证概率变化。

定理 2：校正 GMM 估计量的渐近正态性。在假设 1-6 下，

$$\sqrt{n}(\hat{\theta}^{AI} - \theta_0) \xrightarrow{d} N(0, V^{AI}),$$

其中

$$V^{AI} = (G'WG)^{-1}G'W\Omega^{AI}WG(G'WG)^{-1}.$$

如果使用最优 GMM 权重

$$W = (\Omega^{AI})^{-1},$$

则

$$V^{AI} = (G'(\Omega^{AI})^{-1}G)^{-1}.$$

证明。校正 GMM 的一阶条件为 $\frac{\partial \hat{m}_n^{AI}(\hat{\theta}^{AI})'}{\partial \theta} W_n \hat{m}_n^{AI}(\hat{\theta}^{AI}) = 0$ 。在 θ_0 附近对 $\hat{m}_n^{AI}(\hat{\theta}^{AI})$ 做一阶展开： $\hat{m}_n^{AI}(\hat{\theta}^{AI}) = \hat{m}_n^{AI}(\theta_0) + G(\hat{\theta}^{AI} - \theta_0) + o_p(\|\hat{\theta}^{AI} - \theta_0\|)$ 。将其代入一阶条件并忽略高阶项，得到 $0 = G'W \left[\hat{m}_n^{AI}(\theta_0) + G(\hat{\theta}^{AI} - \theta_0) \right] + o_p(n^{-1/2})$ 。整理得 $G'WG(\hat{\theta}^{AI} - \theta_0) = -G'W\hat{m}_n^{AI}(\theta_0) + o_p(n^{-1/2})$ 。因此 $\sqrt{n}(\hat{\theta}^{AI} - \theta_0) = -(G'WG)^{-1}G'W\sqrt{n}\hat{m}_n^{AI}(\theta_0) + o_p(1)$ 。由假设 6， $\sqrt{n}\hat{m}_n^{AI}(\theta_0) \xrightarrow{d} N(0, \Omega^{AI})$ 。由 Slutsky 定理， $\sqrt{n}(\hat{\theta}^{AI} - \theta_0) \xrightarrow{d} N(0, V^{AI})$ ，其中 $V^{AI} = (G'WG)^{-1}G'W\Omega^{AI}WG(G'WG)^{-1}$ 。证毕。

实践中，可以用样本估计渐近方差。令 $\hat{g}_i^{AI} = g_i^{AI}(\hat{\theta}^{AI})$ ，样本方差矩阵为 $\hat{\Omega}^{AI} = \frac{1}{n} \sum_{i=1}^n \hat{g}_i^{AI} \hat{g}_i^{AI'}$ 。如果需要去均值，也可以使用

$$\hat{\Omega}^{AI} = \frac{1}{n} \sum_{i=1}^n \left(\hat{g}_i^{AI} - \hat{m}_n^{AI}(\hat{\theta}^{AI}) \right) \left(\hat{g}_i^{AI} - \hat{m}_n^{AI}(\hat{\theta}^{AI}) \right)'.$$

估计导数矩阵为 $\hat{G} = \frac{1}{n} \sum_{i=1}^n \frac{\partial g_i^{AI}(\theta)}{\partial \theta'} \Big|_{\theta=\hat{\theta}^{AI}}$ 。于是参数方差估计量为

$$\hat{V}^{AI} = (\hat{G}'W_n\hat{G})^{-1}\hat{G}'W_n\hat{\Omega}^{AI}W_n\hat{G}(\hat{G}'W_n\hat{G})^{-1}.$$

因此第 j 个参数的标准误为 $\widehat{\text{se}}(\hat{\theta}_j^{AI}) = \sqrt{\hat{V}_{jj}^{AI}/n}$ ，对应的 $1 - \alpha$ 置信区间为 $\hat{\theta}_j^{AI} \pm z_{1-\alpha/2}\widehat{\text{se}}(\hat{\theta}_j^{AI})$ 。

3.4 方差比较

为了明确说明本文方法的估计效率优势，我们需要对矫正估计量进行方差分析。本节我们仅比较矫正矩条件与仅使用验证样本的估计量之间的方差，均匀抽样和策略抽样两种不同验证规则下的矫正矩估计量的方差表现分析和验证概率选取有关，将在第四节：验证概率中讨论。

定义仅使用验证集的估计量：

$$\hat{\theta}^V = \arg \min_{\theta} \left[\frac{1}{n_b} \sum_{i:\xi_i=1} g_i(\theta; X_i) \right]' W \left[\frac{1}{n_b} \sum_{i:\xi_i=1} g_i(\theta; X_i) \right].$$

如果验证集是均匀随机抽样, 且 $n_b \rightarrow \infty$, 那么它是一致的。但该估计量只用了 n_b 个真实样本, 所以方差大约是:

$$\frac{1}{n_b} V^V = \frac{1}{n_b} (G'WG)^{-1} G'W \Omega_D W G (G'WG)^{-1},$$

其中

$$\Omega_D = \text{Var}(g_i(\theta_0; X_i)).$$

回顾前文所定义的主动推理校正估计量的方差为

$$\frac{1}{n} V^{AI} = \frac{1}{n} (G'WG)^{-1} G'W \Omega^{AI} W G (G'WG)^{-1}$$

其中

$$\Omega_{\text{active}}^{AI} = \text{Var}(g_i(\theta_0; X_i)) + E \left[\left(\frac{1}{\pi_i} - 1 \right) d_i(\theta_0) d_i(\theta_0)' \right].$$

可以发现, 其渐近方差与仅使用验证集估计量的渐近方差存在两个核心差异。第一, 二者所利用的样本量不同: 仅使用验证集的估计量只依赖于 n_b 个被验证样本, 而校正估计量则在 n 个样本上构造校正矩条件。第二, 校正估计量引入了额外的 IPW 校正方差项, 即由 ξ_i/π_i 放大污染 $d_i(\theta) = g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)$ 所产生的抽样波动, 在上式中表现为 $E \left[\left(\frac{1}{\pi_i} - 1 \right) d_i(\theta_0) d_i(\theta_0)' \right]$, 可能会放大估计量的不稳定性。这个问题严重么, 以及如何缓解呢?

如果机器学习生成变量在二阶段矩条件意义下足够准确, 即 $(g_i(\theta_0; \hat{X}_i) \approx g_i(\theta_0; X_i))$, 那么矩污染项 $(d_i(\theta_0) = g_i(\theta_0; X_i) - g_i(\theta_0; \hat{X}_i))$ 接近于零。此时, 校正矩估计量的方差近似为使用全样本 oracle moment 时的方差, 即接近 $\frac{1}{n} V^{AI}$, 这通常远小于仅使用验证样本估计时的方差 $\frac{1}{n_b} V^V$, 因为 $(n_b \ll n)$ 。当然, 机器学习生成变量不可能在所有样本上都完全准确, 不过, 我们依然可以通过选择验证概率 (π_i) , 使得当某个样本的矩污染较小时, 即 $(d_i(\theta_0) \approx 0)$ 时, 给予较低的验证概率; 而当某个样本可能产生较大的矩污染时, 给予较高的验证概率。这样可以使额外 IPW 方差项 $(d_i(\theta_0) d_i(\theta_0)' (\pi_i^{-1} - 1))$ 在预算约束下尽可能保持较小从而使抽样带来的额外方差始终维持在一个较低的水平。特别地, 对于那些完全没有矩污染的样本, 即 $(g_i(\theta_0; \hat{X}_i) = g_i(\theta_0; X_i))$, 理想情况下可以令 $(\pi_i = 0)$, 因为验证这些样本不会降低校正矩的额外方差。

更通俗地说, 仅使用验证集估计量的方差主要来自只保留 n_b 个真实观测所导致的样本量损失; 而主动推理校正估计量则利用全部 n 个样本中的预测信息, 并仅对预测矩与真实矩之间的污染项进行 IPW 校正。因此, 虽然校正估计量会带来额外的 IPW 抽样方差, 但在现实情境中通常有 $n_b \ll n$, 而仅使用验证集会丢弃大量未验证样本中的有用信息。因此, 只要额外的 IPW 方差小于由样本量缩减所带来的信息损失, 校正估计量的总体方差就可以显著小于验证集估计量。

“额外的 IPW 方差小于由样本量缩减所带来的信息损失” 这个条件是否容易满足? 直观上来看, 真实矩条件与代理矩条件之间的差异 $d_i(\theta_0)$ 通常只集中在一部分预测误差较大或矩污染较严重的观测上。此时, 相较于仅使用少量验证样本进行估计, 校正估计

量能够保留全样本中大量低污染观测所提供的信息，只需通过验证样本校正相对有限的矩污染项。因此，只要 IPW 权重得到适当控制，校正估计量引入的额外抽样方差就有可能小于仅使用验证样本所造成的样本量损失。第六节和第七节的实验结果表明，当验证预算不是过低时，既有验证样本已经能够为风险函数提供足够的训练信息，使其对矩污染强度具有一定预测能力。在这种情况下，主动验证规则可以将更多验证资源分配给预期矩污染较大的样本，而将较少资源分配给代理矩与真实矩差异较小的样本，从而有效降低 IPW 校正项的额外方差。因此，在本文的现实数据环境中，只要验证预算足以支持风险函数的基本训练，主动校正估计量相对于仅使用验证样本和均匀验证校正均表现出更高的统计效率。与此同时，通过将主动验证概率与均匀验证概率混合（详细内容将在 4.4 节中介绍），本文进一步避免了部分样本验证概率过小所导致的极端逆概率权重问题。

4 验证概率

在本节中，我们将寻找能够最小化估计量方差的最优验证概率。进一步地，为了控制实践中可能的方差不稳定现象，我们还会探讨在实际研究中更加稳健的抽样规则。

虽然我们应该关心的是估计量的方差，但讨论矫正矩的方差可以方便地说明选取验证概率的原则。为此，我们还是先探讨矩污染的方差从而提供一些选择验证概率的直觉。据上一节分析，给定完整数据和验证前信息，校正项中由验证随机性引入的额外波动可以写为 $\left(\frac{\xi_i}{\pi_i} - 1\right) d_i(\theta)$ ，其条件方差为 $\text{Var} \left[\left(\frac{\xi_i}{\pi_i} - 1\right) d_i(\theta) \mid X_i, \hat{X}_i \right] = d_i(\theta) d_i(\theta)' \left(\frac{1}{\pi_i} - 1\right)$ 。标量情形下，某一点的额外方差可以写为：

$$\text{Var} \left[\left(\frac{\xi_i}{\pi_i} - 1\right) d_i(\theta) \mid X_i, \hat{X}_i \right] = d_i(\theta)^2 \left(\frac{1}{\pi_i} - 1\right).$$

当 $d_i(\theta)$ 较大时，较小的 π_i 会显著放大校正项的方差；而当 $d_i(\theta)$ 较小时，即使该样本的验证概率较低，其对总体方差的贡献也相对有限。因此，在给定验证预算下，较优的验证规则应当为预期矩污染较大的样本分配更高的验证概率，而为预期矩污染较小的样本分配较低的验证概率。如果可以按照以上规则选取验证样本，我们就可以将最终关心的方差

$$E \left[\text{Var} \left[\left(\frac{\xi_i}{\pi_i} - 1\right) d_i(\theta) \mid X_i, \hat{X}_i \right] \right]$$

维持在一个更小的水平。

4.1 最优验证概率

虽然前文一直在关心矩条件的方差，但我们最终关心的应该是估计量的方差。设共有 q 个矩条件和 p 个参数，即 $g_i(\theta) \in \mathbb{R}^q$ 且 $\theta \in \mathbb{R}^p$ 。在真实参数 θ_0 处，定义由预测误差导致的矩条件污染为

$$d_i(\theta_0) = g_i(\theta_0; X_i) - g_i(\theta_0; \hat{X}_i) \in \mathbb{R}^q.$$

这个 $d_i(\theta_0)$ 是一个 q 维向量, 表示第 i 个样本在不同矩条件方向上造成的污染。然而, 研究者最终关心的通常不是矩条件本身, 而是参数估计量。因此, 需要进一步说明 $d_i(\theta_0)$ 如何传导到目标估计量上。

令样本平均矩为 $\hat{m}_n(\theta_0) = n^{-1} \sum_{i=1}^n g_i(\theta_0)$ 。在 GMM 一阶展开下, 有

$$\hat{\theta} - \theta_0 \approx -M\hat{m}_n(\theta_0), \quad M = (G'WG)^{-1}G'W.$$

样本平均矩中的误差不会直接等于参数误差, 而是先进入 $\hat{m}_n(\theta_0)$, 再经过矩阵 M 传导到 $\hat{\theta} - \theta_0$, M 把矩条件污染映射为参数估计一阶误差。也就是说, 如果样本矩中包含污染项 $d_i(\theta_0)$, 那么第 i 个样本对参数向量的一阶影响为 $-n^{-1}Md_i(\theta_0)$ 。在推导最优验证概率时, 常数 $-n^{-1}$ 不影响样本之间的排序, 因此可以只关注 $Md_i(\theta_0)$ 。

现在让我们把上述理论具体到本文研究的情景。为了聚焦于本文关注的目标参数, 令

$$M = (G'WG)^{-1}G'W,$$

其中 M 表示矩条件污染传导到目标参数的一阶影响矩阵。将校正矩 $g_i^{AI}(\theta_0) = g_i(\theta_0; X_i) + \left(\frac{\xi_i}{\pi_i} - 1\right)d_i(\theta_0)$ 通过 GMM 一阶影响矩阵映射到目标参数后, 额外噪声变为

$$\left(\frac{\xi_i}{\pi_i} - 1\right)Md_i(\theta_0).$$

由于 $E[\xi_i/\pi_i - 1 | X_i, \hat{X}_i] = 0$, 该项是零均值噪声, 因此不会引入系统性偏误, 但它会带来额外方差。给定 $X_i, \hat{X}_i$ 后, $Md_i(\theta_0)$ 是固定的, 而随机性只来自验证指示变量 ξ_i , 有 $\text{Var}\left(\frac{\xi_i}{\pi_i} - 1 | X_i, \hat{X}_i\right) = \frac{1}{\pi_i} - 1$, 所以有

$$\text{Var}\left[\left(\frac{\xi_i}{\pi_i} - 1\right)Md_i(\theta_0) | X_i, \hat{X}_i\right] = (Md_i(\theta_0))^2 \left(\frac{1}{\pi_i} - 1\right).$$

因此, 额外抽样方差期望为 $E\left[(Md_i(\theta_0))^2 \left(\frac{1}{\pi_i} - 1\right)\right]$ 。由于 $E[(Md_i(\theta_0))^2]$ 与 π_i 无关, 所以选择 π_i 时只需要最小化 $E\left[\frac{(Md_i(\theta_0))^2}{\pi_i}\right]$ 。于是, 主动验证的目标可以写成

$$\begin{aligned} \min_{\pi(\cdot)} \quad & E\left[\frac{h(\hat{X}_i)}{\pi(\hat{X}_i)}\right] \\ \text{s.t.} \quad & E[\pi(\hat{X}_i)] \leq \rho. \end{aligned}$$

其中条件为预算约束, $\rho = \frac{n_b}{n}$ 表示平均验证比例。由拉格朗日一阶条件可得, 在忽略 $\pi(\hat{X}_i) \leq 1$ 上界约束的内点情形下,

$$\pi^{opt}(\hat{X}_i) \propto \sqrt{h(\hat{X}_i)} = \sqrt{E[(Md_i(\theta_0))^2 | \hat{X}_i]}.$$

下面我们将给出这个 oracle rule 的正式证明。

命题 2: oracle active rule 忽略上界约束 $\pi(\hat{X}_i) \leq 1$ 的情形下, 给定验证预算 $E[\pi(\hat{X}_i)] \leq \rho$, 使 $E\left[\frac{h(\hat{X}_i)}{\pi(\hat{X}_i)}\right]$ 能够取到最小的验证概率满足

$$\pi^{opt}(\hat{X}_i) \propto \sqrt{h(\hat{X}_i)} = \sqrt{E[(Md_i)^2 | \hat{X}_i]}.$$

如果预算约束以等号成立, 则

$$\pi^{opt}(\hat{X}_i) = \rho \frac{\sqrt{h(\hat{X}_i)}}{E[\sqrt{h(\hat{X}_i)}]}.$$

证明。 考虑优化问题 $\min_{\pi(\cdot)} E\left[\frac{h(\hat{X}_i)}{\pi(\hat{X}_i)}\right]$ 满足 $E[\pi(\hat{X}_i)] = \rho$ 。构造拉格朗日函数 $\mathcal{L} = E\left[\frac{h(\hat{X}_i)}{\pi(\hat{X}_i)}\right] + \lambda \left(E[\pi(\hat{X}_i)] - \rho\right)$ 。对每个 $\hat{X}_i$ 处的 $\pi(\hat{X}_i)$ 求一阶条件: $-\frac{h(\hat{X}_i)}{\pi(\hat{X}_i)^2} + \lambda = 0$ 。因此 $\pi(\hat{X}_i)^2 = \frac{h(\hat{X}_i)}{\lambda}$ 。由于 $\pi(\hat{X}_i) > 0$, 得到 $\pi^{opt}(\hat{X}_i) = \frac{1}{\sqrt{\lambda}} \sqrt{h(\hat{X}_i)}$ 。令 $c = \frac{1}{\sqrt{\lambda}}$, 则 $\pi^{opt}(\hat{X}_i) = c\sqrt{h(\hat{X}_i)}$ 。由预算约束 $E[\pi^{opt}(\hat{X}_i)] = \rho$ 可得 $cE[\sqrt{h(\hat{X}_i)}] = \rho$ 。因此 $c = \frac{\rho}{E[\sqrt{h(\hat{X}_i)}]}$ 。所以 $\pi^{opt}(\hat{X}_i) = \rho \frac{\sqrt{h(\hat{X}_i)}}{E[\sqrt{h(\hat{X}_i)}]}$ 。证毕。

上面的推导忽略了验证概率不能超过 1 的约束。若加入约束 $0 < \pi(\hat{X}_i) \leq 1$, 则最优规则变成截断形式:

$$\pi^{opt}(\hat{X}_i) = \min \left\{ 1, c\sqrt{h(\hat{X}_i)} \right\} = \min \left\{ 1, c\sqrt{E[(Md_i)^2 | \hat{X}_i]} \right\}$$

由于 M 的真实值在实际中未知, 因此本文可以使用历史验证样本估计 M , 并构造 $\hat{B} = \hat{M}'\hat{M}$ 。此时条件污染风险可以写成 $\hat{h}(\hat{X}_i) = E\left[d_i'\hat{B}d_i | \hat{X}_i\right] = E\left[(\hat{M}d_i)^2 | \hat{X}_i\right]$ 对应的 plug-in 主动验证规则为

$$\pi_i^{plug-in} \propto \sqrt{E\left[(\hat{M}d_i)^2 | \hat{X}_i\right]}$$

如果 $\hat{M}$ 是 M 的一致估计, 则该规则可以视为 oracle active rule 的可行近似。

4.2 与均匀验证的效率比较

均匀验证规则为 $\pi^{unif}(\hat{X}_i) = \rho$ 。在标量目标下, 均匀验证的目标函数值为 $E\left[\frac{h(\hat{X}_i)}{\rho}\right] = \frac{E[h(\hat{X}_i)]}{\rho}$ 。oracle active rule 的目标函数值为 $E\left[\frac{h(\hat{X}_i)}{\pi^{opt}(\hat{X}_i)}\right]$ 。由 $\pi^{opt}(\hat{X}_i) = \rho \frac{\sqrt{h(\hat{X}_i)}}{E[\sqrt{h(\hat{X}_i)}]}$ 可得 $E\left[\frac{h(\hat{X}_i)}{\pi^{opt}(\hat{X}_i)}\right] = E\left[\frac{h(\hat{X}_i)E[\sqrt{h(\hat{X}_i)}]}{\rho\sqrt{h(\hat{X}_i)}}\right]$, 整理得 $E\left[\frac{h(\hat{X}_i)}{\pi^{opt}(\hat{X}_i)}\right] = \frac{E[\sqrt{h(\hat{X}_i)}]^2}{\rho}$ 。

由 Jensen 不等式或 Cauchy-Schwarz 不等式, $E[\sqrt{h(\hat{X}_i)}]^2 \leq E[h(\hat{X}_i)]$, $\frac{E[\sqrt{h(\hat{X}_i)}]^2}{\rho} \leq \frac{E[h(\hat{X}_i)]}{\rho}$ 。这说明 oracle active rule 的方差目标值不大于均匀验证, 只有当 $h(\hat{X}_i)$ 几乎处处为常数时, 二者才相同。换言之, 如果不同样本的矩条件污染存在异质性, 主动验证可以严格优于均匀验证。

Algorithm 1 可行的主动验证规则

Require: 未验证数据 $\{Y_i, \hat{X}_i\}_{i=1}^n$, 验证预算 n_b , pilot $\mathcal{I}_p \subset \{1, \dots, n\}$, $|\mathcal{I}_p| = n_p$ (验证样本量为 n_p), 初始估计量 $\hat{\theta}$, 候选缩放参数集合 H

Ensure: 主动验证概率 $\{\pi_i^{\text{active}}\}_{i=1}^n$

```

1: for  $i \in \mathcal{I}_p$  do
2:   计算该样本的矩条件污染:  $d_i(\hat{\theta}) = g_i(\hat{\theta}; X_i) - g_i(\hat{\theta}; \hat{X}_i)$ 
3: end for
4: 基于 pilot 验证样本估计条件参数污染预测模型:  $\hat{h}(\hat{X}_i) \approx E[(Md_i)^2 | \hat{X}_i]$ 
5: 构造主动验证得分:  $u_i = \sqrt{\hat{h}(\hat{X}_i)}$ 
6: 选择缩放参数:  $\hat{\eta} = \max \{\eta \in H : \eta \sum_{i=1}^n u_i \leq n_b\}$ 
7: for  $i = 1, \dots, n$  do
8:   设定主动验证概率:  $\pi_i^{\text{active}} = \hat{\eta} u_i$ 
9: end for
10: 输出主动验证概率  $\{\pi_i^{\text{active}}\}_{i=1}^n$ 

```

4.3 实践中的主动验证规则

从上一节的推导中我们可以看出, oracle rule 依赖 $h(\hat{X}_i) = E[(Md_i)^2 | \hat{X}_i]$, 但是 $d_i = g_i(\theta; X_i) - g_i(\theta; \hat{X}_i)$ 在未验证样本中不可观测。因此现实要先用既有验证集中的真实 X_i 计算 d_i , 再训练参数污染预测模型 $\hat{h}(\hat{X}_i)$, 构造 $u_i = \sqrt{\hat{h}(\hat{X}_i)}$, 最后令 $\pi_i^{\text{active}} = \eta u_i$, 并通过选取合适的 η 满足预算约束以保证该方法的现实可行性。具体步骤如下:

第一步, 在 pilot 样本中计算 $d_i(\hat{\theta}) = g_i(\hat{\theta}; X_i) - g_i(\hat{\theta}; \hat{X}_i)$, 其中 $\hat{\theta}$ 可以使用既有验证集中真实 X_i 估计得到的估计量。由于我们使用 $\hat{\theta}$ 替换掉了 θ , 因此实际计算中需要使用 crossfitting。

第二步, 训练一个参数污染预测模型 $\hat{h}(\hat{X}_i) \approx E[(Md_i)^2 | \hat{X}_i]$ 。也可以先估计 $r(\hat{X}_i) \approx \sqrt{E[(X_i - \hat{X}_i)^2 | \hat{X}_i]}$, 再根据具体模型结构乘以相应的 moment weight。

第三步, 构造 active score: $u_i = \sqrt{\hat{h}(\hat{X}_i)}$, 然后将其转化为验证概率: $\pi_i^{\text{active}} = \eta u_i$, 其中 η 为 $\hat{\eta} = \max \{\eta \in H : \eta \sum_{i=1}^n u_i \leq n_b\}$, 由于验证样本数的期望是 $E[\sum_{i=1}^n \xi_i] = \sum_{i=1}^n E(\xi_i) = \sum_{i=1}^n \pi_i$ 因此按照上述规则选取 $\hat{\eta}$ 可以用来满足预算约束 $\sum_{i=1}^n \pi_i^{\text{active}} \approx n_b$ 。

4.4 更加稳健的抽样规则

为了最大化验证效率, 主动验证概率应满足 $\pi_i^{\text{act}} \propto u(\hat{X}_i)$ 。然而, $u(\hat{X}_i)$ 本身是估计得到的, 不可能完全等同于真实污染强度。若污染强度预测器错误地将某些高污染样本赋予接近于零的预测污染, 即 $u(\hat{X}_i) \approx 0$, 则这些样本的主动验证概率 π_i^{act} 会非常小。一旦这类样本被验证, 校正项中的逆概率权重 $1/\pi_i^{\text{act}}$ 会被极度放大, 从而导致估计量非

常不稳定（方差大）。上述现象在 $\hat{h}(X_i)$ 非常不准确时更加令人担忧。

为缓解这一问题，本文将主动验证规则与均匀验证规则进行混合。记均匀验证概率为 $\pi_i^{\text{unif}} = \frac{n_b}{n}$ ，对于给定的混合参数 $\tau \in [0, 1]$ ，最终验证概率定义为

$$\pi_i^{(\tau)} = (1 - \tau)\pi_i^{\text{act}} + \tau\pi_i^{\text{unif}}.$$

当 $\tau = 0$ 时，该规则退化为纯主动验证；当 $\tau = 1$ 时，该规则退化为均匀验证。只要 $\tau > 0$ ，所有样本的验证概率都具有正下界： $\pi_i^{(\tau)} \geq \tau \frac{n_b}{n}$ 。因此，混合规则可以避免由于 $u(\hat{X}_i)$ 过小而造成的极端逆概率权重，提高主动校正估计量的稳定性。我们可以用既有验证集选择混合参数 τ 。设既有验证集数据为 $\{Y_i^h, \hat{X}_i^h, X_i^h\}_{i=1}^{n_h}$ ，其中 X_i^h 表示历史样本中已经人工验证得到的真实变量。对于每一个候选 τ ，先根据历史样本计算相应的混合验证概率 $\pi_i^{(\tau),h} = (1 - \tau)\pi_i^{\text{act},h} + \tau\pi_i^{\text{unif},h}$ ，将这一概率作为主动验证概率进行使用，随后调整 τ 以最小化历史数据上对应的方差代理项：

$$\hat{\tau} = \arg \min_{\tau \in [0,1]} \sum_{i=1}^{n_h} \frac{\left(\widehat{M}d_i^h(\hat{\theta})\right)^2}{\pi_i^{(\tau),h}}.$$

该目标函数对应于主动校正估计量渐近方差中与抽样规则相关的部分。若污染强度预测器 $u(\hat{X}_i)$ 在历史数据上表现良好，则较小的 τ 会被选择，从而更多依赖主动验证；若 $u(\hat{X}_i)$ 在历史数据上不稳定，较大的 τ 会被选择，从而增加均匀验证概率的比例。

5 主动验证在计量经济学回归模型中的应用

本节我们给出常用计量模型中的矩污染形式，并分析这些模型中的最优验证规则。

5.1 OLS

在文章 xx 节中，我们曾经使用一元线性回归模型来说明机器学习生成变量对 OLS 估计的影响。下面我们将在多元回归问题中更一般地分析 OLS 中的矩污染形式，并从中导出 OLS 下的 oracle active rule。

首先考虑普通线性回归。真实模型为

$$Y_i = \beta_0 X_i + W_i' \gamma_0 + \varepsilon_i,$$

其中 X_i 是真实解释变量， W_i 是控制变量和截距项。为了简化记号，先将 Y_i 、 X_i 和 $\hat{X}_i$ 对 W_i 残差化： $\tilde{Y}_i = Y_i - \Pi_W Y_i$ ， $\tilde{X}_i = X_i - \Pi_W X_i$ ， $\tilde{\hat{X}}_i = \hat{X}_i - \Pi_W \hat{X}_i$ 。其中 Π_W 表示对控制变量 W_i 的线性投影。残差化后，真实 OLS 矩可以写成 $g_i^{\text{OLS}}(\beta; X_i) = \tilde{X}_i(\tilde{Y}_i - \beta \tilde{X}_i)$ 。如果直接使用机器学习生成变量 $\hat{X}_i$ ，朴素 OLS 矩为 $g_i^{\text{OLS}}(\beta; \hat{X}_i) = \tilde{\hat{X}}_i(\tilde{Y}_i - \beta \tilde{\hat{X}}_i)$ 。因此，OLS 中的矩污染为

$$d_i^{\text{OLS}}(\beta) = g_i^{\text{OLS}}(\beta; X_i) - g_i^{\text{OLS}}(\beta; \hat{X}_i).$$

也就是

$$d_i^{OLS}(\beta) = \tilde{X}_i(\tilde{Y}_i - \beta\tilde{X}_i) - \tilde{D}_i(\tilde{Y}_i - \beta\tilde{D}_i).$$

令 $\tilde{e}_i = \tilde{D}_i - \tilde{X}_i$ 。则 $\tilde{D}_i = \tilde{X}_i + \tilde{e}_i$ 。在真实参数 β_0 处, 若 $\tilde{Y}_i = \beta_0\tilde{X}_i + \tilde{e}_i$, 则朴素 OLS 矩为 $g_i^{OLS}(\beta_0; \hat{X}_i) = (\tilde{X}_i + \tilde{e}_i)(\tilde{e}_i - \beta_0\tilde{e}_i)$ 。真实 OLS 矩为 $g_i^{OLS}(\beta_0; X_i) = \tilde{X}_i\tilde{e}_i$ 。因此, $g_i^{OLS}(\beta_0; \hat{X}_i) - g_i^{OLS}(\beta_0; X_i) = \tilde{e}_i\tilde{e}_i - \beta_0\tilde{X}_i\tilde{e}_i - \beta_0\tilde{e}_i^2$ 。所以

$$d_i^{OLS}(\beta_0) = -\tilde{e}_i\tilde{e}_i + \beta_0\tilde{X}_i\tilde{e}_i + \beta_0\tilde{e}_i^2.$$

从这个式子我们也可以进一步看出, 在 OLS 中, 机器学习预测误差对目标矩条件的污染不是简单的 $\tilde{e}_i = \tilde{D}_i - \tilde{X}_i$, 而是包含 $\tilde{e}_i\tilde{e}_i$ 、 $\tilde{X}_i\tilde{e}_i$ 、 $\tilde{e}_i^2$ 等项。又因为对于参数的污染可以写成对于矩条件的污染乘以一阶影响矩阵, 因此, OLS 下最值得验证的样本不是单纯预测误差最大的样本, 而是对 $\tilde{X}_i(\tilde{Y}_i - \beta\tilde{X}_i)$ 污染最大的样本。

对应的 oracle active rule 则可以写成

$$\pi_i^{OLS,opt} \propto \sqrt{E[(d_i^{OLS}(\beta_0))^2 | \hat{X}_i]},$$

5.2 IV

首先考虑仅使用一个工具变量的情形, 设工具变量为 Z_i , 残差化后得到 $\tilde{Z}_i$ 真实 IV 矩为 $g_i^{IV}(\beta; X_i) = \tilde{Z}_i(\tilde{Y}_i - \beta\tilde{X}_i)$ 。使用机器学习生成变量时, 朴素 IV 矩为 $g_i^{IV}(\beta; \hat{X}_i) = \tilde{Z}_i(\tilde{Y}_i - \beta\tilde{D}_i)$ 。因此, IV 中的矩污染为 $d_i^{IV}(\beta) = g_i^{IV}(\beta; X_i) - g_i^{IV}(\beta; \hat{X}_i)$ 。展开得 $d_i^{IV}(\beta) = \tilde{Z}_i(\tilde{Y}_i - \beta\tilde{X}_i) - \tilde{Z}_i(\tilde{Y}_i - \beta\tilde{D}_i)$ 。整理可得 $d_i^{IV}(\beta) = \beta\tilde{Z}_i(\tilde{D}_i - \tilde{X}_i)$ 。令 $\tilde{e}_i = \tilde{D}_i - \tilde{X}_i$, 则 $d_i^{IV}(\beta) = \beta\tilde{Z}_i\tilde{e}_i$ 。在真实参数 β_0 处, $d_i^{IV}(\beta_0) = \beta_0\tilde{Z}_i\tilde{e}_i$ 。

因此, 标量 IV 下的 oracle active rule 为

$$\pi_i^{IV,opt} \propto \sqrt{E[\beta_0^2\tilde{Z}_i^2\tilde{e}_i^2 | \hat{X}_i]}.$$

由于 β_0 是常数, 且 $\tilde{Z}_i$ 在验证前可观测, 所以 IV 情境下的最优验证规则为

$$\pi_i^{IV,opt} \propto |\tilde{Z}_i| \sqrt{E[\tilde{e}_i^2 | \hat{X}_i]}$$

如果有多个工具变量, $\tilde{Z}_i \in \mathbb{R}^q$, 则 $g_i^{IV}(\beta; X_i) = \tilde{Z}_i(\tilde{Y}_i - \beta\tilde{X}_i)$, 其中 $g_i^{IV}(\beta; X_i) \in \mathbb{R}^q$ 。污染项为 $d_i^{IV}(\beta) = \beta\tilde{Z}_i\tilde{e}_i$ 。如果目标是降低 GMM 加权的矩污染, 可以取权重矩阵 W , 得到 $\pi_i^{IV-GMM,opt} \propto \sqrt{E[d_i^{IV}(\beta_0)'Wd_i^{IV}(\beta_0) | \hat{X}_i]}$ 。代入 $d_i^{IV}(\beta_0) = \beta_0\tilde{Z}_i\tilde{e}_i$, 得到

$$\pi_i^{IV-GMM,opt} \propto \sqrt{E[\beta_0^2\tilde{e}_i^2\tilde{Z}_i'W\tilde{Z}_i | \hat{X}_i]}.$$

因此

$$\pi_i^{IV-GMM,opt} \propto \|W^{1/2}\tilde{Z}_i\| \sqrt{E[\tilde{e}_i^2 | \hat{X}_i]}.$$

弱工具变量下的情况会更加复杂, 暂时不讨论。

5.3 DiD

接下来考虑双重差分法。DiD 的核心是比较处理组和控制组在处理前后的变化。如果处理变量是从非结构化数据中由机器学习生成的，那么机器学习误差会污染 DiD 的识别矩条件。

为了简化，先考虑两期两组 DiD。令 $\Delta Y_i = Y_{i1} - Y_{i0}$ 表示个体 i 的结果变化，真实处理状态为 $X_i \in \{0, 1\}$ 。经典 DiD 可以写成 $\Delta Y_i = \alpha_0 + \tau_0 X_i + \eta_i$ ，其中 α_0 是对照组的平均结果变化， τ_0 是 ATT。需要注意的是，如果回归中包含截距项，则不能直接使用 $X_i(\Delta Y_i - \tau_0 X_i)$ 作为对应的矩，而应当先对常数项进行残差化。令 $\bar{\Delta Y} = n^{-1} \sum_{i=1}^n \Delta Y_i$ 、 $\bar{D} = n^{-1} \sum_{i=1}^n X_i$ ，并定义去均值变量 $\widetilde{\Delta Y}_i = \Delta Y_i - \bar{\Delta Y}$ 、 $\widetilde{X}_i = X_i - \bar{D}$ 。此时，含截距 DiD 回归中关于 τ 的矩可以写成

$$g_i^{DiD}(\tau; X_i) = \widetilde{X}_i \left(\widetilde{\Delta Y}_i - \tau \widetilde{X}_i \right).$$

如果使用机器学习生成的处理状态 $\hat{X}_i = X_i + e_i$ ，则同样需要对 $\hat{X}_i$ 去均值。令 $\bar{\hat{D}} = n^{-1} \sum_{i=1}^n \hat{X}_i$ ，并定义 $\widetilde{\hat{D}}_i = \hat{X}_i - \bar{\hat{D}}$ 。相应的朴素 DiD 矩为

$$g_i^{DiD}(\tau; \hat{X}_i) = \widetilde{\hat{D}}_i \left(\widetilde{\Delta Y}_i - \tau \widetilde{\hat{D}}_i \right).$$

因此，DiD 中的矩污染为 $d_i^{DiD}(\tau) = g_i^{DiD}(\tau; X_i) - g_i^{DiD}(\tau; \hat{X}_i)$ ，即

$$d_i^{DiD}(\tau) = \widetilde{X}_i \left(\widetilde{\Delta Y}_i - \tau \widetilde{X}_i \right) - \widetilde{\hat{D}}_i \left(\widetilde{\Delta Y}_i - \tau \widetilde{\hat{D}}_i \right).$$

为了看清污染项的结构，令 $\tilde{e}_i = \widetilde{\hat{D}}_i - \widetilde{X}_i$ 。在真实参数 τ_0 处，若去均值后的模型满足 $\widetilde{\Delta Y}_i = \tau_0 \widetilde{X}_i + \tilde{\eta}_i$ ，则

$$g_i^{DiD}(\tau_0; \hat{X}_i) = (\widetilde{X}_i + \tilde{e}_i) (\tilde{\eta}_i - \tau_0 \tilde{e}_i).$$

真实矩为 $g_i^{DiD}(\tau_0; X_i) = \widetilde{X}_i \tilde{\eta}_i$ 。因此，

$$g_i^{DiD}(\tau_0; \hat{X}_i) - g_i^{DiD}(\tau_0; X_i) = \tilde{e}_i \tilde{\eta}_i - \tau_0 \widetilde{X}_i \tilde{e}_i - \tau_0 \tilde{e}_i^2.$$

所以，

$$d_i^{DiD}(\tau_0) = -\tilde{e}_i \tilde{\eta}_i + \tau_0 \widetilde{X}_i \tilde{e}_i + \tau_0 \tilde{e}_i^2.$$

这个形式类似 OLS，但 DiD 的特殊之处在于 ΔY_i 是处理前后的结果变化， X_i 是处理组身份。由于含截距的 DiD 实际上依赖的是 X_i 相对于其均值的变化，即 $\widetilde{X}_i = X_i - \bar{D}$ ，所以最值得验证的样本不是处理分类中最不确定的样本，而是那些因错误处理分类而最可能改变“处理组与对照组之间的变化差异”的样本。换言之，主动验证概率应当更多分配给 $|d_i^{DiD}(\tau_0)|$ 或其条件二阶矩 $E[(d_i^{DiD}(\tau_0))^2 | \hat{X}_i]$ 较大的观测，而不是简单按照分类不确定性排序。

对应的 oracle active rule 为：

$$\pi_i^* \propto \sqrt{E \left[(d_i^{DiD}(\tau_0))^2 | \hat{X}_i \right]},$$

并在预算约束 $\sum_{i=1}^n \pi_i^* = n_b$ 与概率约束 $0 < \pi \leq \pi_i^* \leq 1$ 下进行归一化。

在含截距的两期两组 DiD 中, 由于 $d_i^{DiD}(\tau_0) = -\tilde{e}_i \tilde{\eta}_i + \tau_0 \tilde{X}_i \tilde{e}_i + \tau_0 \tilde{e}_i^2$, 所以 oracle rule 等价于将更多验证预算分配给

$$E \left[\left(-\tilde{e}_i \tilde{\eta}_i + \tau_0 \tilde{X}_i \tilde{e}_i + \tau_0 \tilde{e}_i^2 \right)^2 \mid \tilde{X}_i \right]$$

较大的观测。

同样地, DiD 的真实处理效应可以写成处理组与对照组在结果变化上的期望差, 即 $\tau_0 = E[\Delta Y_i \mid D_i = 1] - E[\Delta Y_i \mid D_i = 0]$ 。在含截距的线性回归表示下, 这一参数也可以写成 $\tau_0 = E[\tilde{D}_i \Delta Y_i] / E[\tilde{D}_i^2]$, 其中 $\tilde{D}_i = D_i - E[D_i]$ 。因此, 机器学习生成的处理状态是否会严重影响 DiD 估计, 并不只取决于处理分类器的总体错误率, 而取决于这些错误是否会显著改变上述处理组一对对照组的结果变化差异。换言之, 即使处理状态的预测错误率较高, 如果错误主要发生在对 $E[\Delta Y_i \mid D_i = 1] - E[\Delta Y_i \mid D_i = 0]$ 贡献较小的观测上, 或者这些误分类不会显著改变处理组与对照组之间的变化对比, 那么其对 DiD 估计量的影响可能仍然有限。相反, 即使总体错误率不高, 只要误分类集中发生在对处理组一对对照组变化差异具有较大影响的观测上, 就可能造成较大的矩条件污染。因此, 在 DiD 设定下, 主动验证规则不应简单按照处理分类器的不确定性或错误概率排序, 而应优先验证那些误分类最可能改变 DiD 识别对比、进而对 τ_0 估计产生较大影响的样本。

5.4 RD: 这部分还没有写完, 只是草稿

最后考虑断点回归。

RD 的核心是断点附近的局部比较。Sharp RD 可以写成左右两侧局部矩。设真实 running variable 为 R_i , cutoff 为 c 。为了简化记号, 令 $X_i = R_i - c$ 。Sharp RD 中, 处理状态由 $X_i = 1\{R_i \geq c\}$ 决定。在 RD 里, 我们要估计的是 cutoff 两侧的条件期望极限:

$$\mu_+(c) = \lim_{r \downarrow c} E[Y_i \mid R_i = r], \quad \mu_-(c) = \lim_{r \uparrow c} E[Y_i \mid R_i = r].$$

RD 参数可以通过 cutoff 附近的局部线性回归估计。令 $K_h(X_i) = \frac{1}{h} K\left(\frac{X_i}{h}\right)$ 为核权重, $p(X_i) = (1, X_i) = (1, R_i - c)'$ 为局部线性基函数。

我们的估计式为

$$\alpha_+ = \arg \min_{\alpha_+} \sum_{i: R_i \geq c} K_h(R_i - c) [Y_i - p(R_i - c)' \alpha_+]^2,$$

估计出来后, $\alpha_{+,0}$ 就是右侧条件期望在 cutoff 处的估计: $\mu_+(c) = \alpha_{+,0}$ 。同理, 左侧用

$$\alpha_- = \arg \min_{\alpha_-} \sum_{i: R_i < c} K_h(R_i - c) [Y_i - p(R_i - c)' \alpha_-]^2,$$

得到 $\mu_-(c) = \alpha_{-,0}$ 。所以 RD 估计量是

$$\tau_{RD} = \mu_+(c) - \mu_-(c) = \alpha_{+,0} - \alpha_{-,0}.$$

如何把局部线性 RD 回归改写成矩条件（一阶条件）的形式？先看右侧局部线性回归。右侧估计的是：

$$\hat{\alpha}_+ = \arg \min_{\alpha_+} \sum_{i=1}^n \mathbf{1}\{R_i \geq c\} K_h(R_i - c) [Y_i - p(R_i - c)' \alpha_+]^2.$$

这个就是 cutoff 右侧的加权 OLS。对 α_+ 求一阶条件，就得到：

$$\sum_{i=1}^n \mathbf{1}\{R_i \geq c\} K_h(R_i - c) p(R_i - c) [Y_i - p(R_i - c)' \alpha_+] = 0.$$

所以把每个样本贡献定义成

$$g_{i,+}^{RD}(\alpha_+; R_i) = \mathbf{1}\{R_i \geq c\} K_h(R_i - c) p(R_i - c) [Y_i - p(R_i - c)' \alpha_+],$$

就可以写成样本矩：

$$\frac{1}{n} \sum_{i=1}^n g_{i,+}^{RD}(\alpha_+; R_i) = 0.$$

其中 $\mathbf{1}\{R_i \geq c\}$ 表示只使用 cutoff 右侧样本。 $K_h(R_i - c)$ 表示核权重，越靠近 cutoff 的样本权重越大。 $p(R_i - c) = (1, R_i - c)'$ 表示局部线性回归的解释变量，也就是截距项和斜率项。 $Y_i - p(R_i - c)' \alpha_+$ 表示残差。所以整个

$$K_h(R_i - c) p(R_i - c) [Y_i - p(R_i - c)' \alpha_+]$$

本质上就是“加权解释变量 $\times$ 残差”。这正是 OLS 一阶条件的形式。

左侧也是一样。左侧局部线性回归是：

$$\hat{\alpha}_- = \arg \min_{\alpha_-} \sum_{i=1}^n \mathbf{1}\{R_i < c\} K_h(R_i - c) [Y_i - p(R_i - c)' \alpha_-]^2.$$

对应的一阶条件是：

$$\sum_{i=1}^n \mathbf{1}\{R_i < c\} K_h(R_i - c) p(R_i - c) [Y_i - p(R_i - c)' \alpha_-] = 0.$$

因此定义左侧矩：

$$g_{i,-}^{RD}(\alpha_-; R_i) = \mathbf{1}\{R_i < c\} K_h(R_i - c) p(R_i - c) [Y_i - p(R_i - c)' \alpha_-].$$

所以这两个式子的意思就是： $g_{i,+}^{RD}(\alpha_+; R_i)$ 是右侧局部线性回归的一阶条件中的单个样本贡献； $g_{i,-}^{RD}(\alpha_-; R_i)$ 是左侧局部线性回归的一阶条件中的单个样本贡献。它们加总为 0，就等价于做左右两侧的局部线性加权回归。最后 RD 参数是左右两侧截距之差：

$$\tau_{RD} = \alpha_{+,0} - \alpha_{-,0}.$$

因此，这个写法只是为了把 RD 放进你文章的统一矩条件框架里。原来局部线性 RD 是“回归形式”，现在写成了“矩形式”，方便后面定义污染项：

$$d_i^{RD}(\theta) = g_i^{RD}(\theta; R_i) - g_i^{RD}(\theta; \hat{R}_i),$$

将左右两侧合并，RD 的矩污染可以写为

$$d_i^{RD}(\theta) = \begin{pmatrix} d_{i,+}^{RD}(\alpha_+) \\ d_{i,-}^{RD}(\alpha_-) \end{pmatrix},$$

其中

$$\theta = (\alpha'_+, \alpha'_-)'.$$

RD 的特殊之处在于：远离 cutoff 的样本即使 running variable 预测误差很大，也未必重要；而 cutoff 附近的样本即使预测误差不大，也可能因为跨过 cutoff 而严重污染 RD 矩。尤其是当 $R_i < c$ 但 $\hat{R}_i \geq c$ ，或者 $R_i \geq c$ 但 $\hat{R}_i < c$ ，样本会被错误分配到 cutoff 的另一侧，从而直接污染 RD 识别。因此 RD 的主动验证不应简单验证 $|\hat{R}_i - R_i|$ 最大的样本，而应验证那些对局部 RD 矩影响最大的样本。对应的 oracle rule 为

$$\pi_i^{RD,opt} \propto \sqrt{E[d_i^{RD}(\theta_0)' B d_i^{RD}(\theta_0) \mid \hat{X}_i]}.$$

如果关注 RD treatment effect $\tau = \alpha_{+,0} - \alpha_{-,0}$ ，则可以使用对应的参数影响方向 a_τ ，得到

$$\pi_i^{RD,opt} \propto \sqrt{E[(a'_\tau d_i^{RD}(\theta_0))^2 \mid \hat{X}_i]}.$$

在实践中，可以将 RD 的 active score 近似写成

$$u_i^{RD} = K_h(\hat{R}_i - c) \cdot r_R(\hat{X}_i) \cdot s_{i,j}^{switch},$$

其中 $r_R(\hat{X}_i) \approx \sqrt{E[(\hat{R}_i - R_i)^2 \mid \hat{X}_i]}$ 表示 running variable 的预测误差风险， $K_h(\hat{R}_i - c)$ 表示样本在 cutoff 附近的局部权重， $s_{i,j}^{switch}$ 表示样本跨越 cutoff 的风险。一个简单的选择是使用历史验证集计算

$$s_{i,j}^{switch} = P((R_i - c)(\hat{R}_i - c) < 0 \mid \hat{X}_i),$$

即真实 running variable 和预测 running variable 位于 cutoff 两侧的概率。这个分数体现了 RD 的核心特征：最值得验证的是 cutoff 附近、具有较高 side-switching 风险、且对局部估计权重较大的样本。

若是 fuzzy RD，处理状态 X_i 不是由 cutoff 完全决定，而是 cutoff 附近的处理概率发生跳跃。此时可以写成局部 IV 矩条件：

$$g_i^{FRD}(\beta; X_i) = K_h(R_i - c) Z_i^{RD} (Y_i - \beta X_i),$$

其中

$$Z_i^{RD} = 1\{R_i \geq c\}.$$

如果 X_i 是机器学习生成变量，则污染项为

$$d_i^{FRD}(\beta) = K_h(R_i - c)Z_i^{RD}(Y_i - \beta X_i) - K_h(R_i - c)Z_i^{RD}(Y_i - \beta \hat{X}_i).$$

因此

$$d_i^{FRD}(\beta) = \beta K_h(R_i - c)Z_i^{RD}(\hat{X}_i - X_i).$$

所以 fuzzy RD 的验证规则为

$$\pi_i^{FRD,opt} \propto K_h(R_i - c)|Z_i^{RD}|\sqrt{E[(\hat{X}_i - X_i)^2 | \hat{X}_i]}.$$

这说明 fuzzy RD 中最值得验证的样本是 cutoff 附近、局部权重高、且 treatment prediction error 风险大的样本。

6 现实数据集表现

6.1 数据描述和任务说明

本节使用的数据与 (Allon et al., 2023) 的现实数据分析基本一致，因此数据描述和任务说明部分可参见该文的第 6.1 节。为了便于阅读，我们将 (Allon et al., 2023) 的相关数据描述和任务说明摘录如下：

Civil Comments 平台是一个面向独立新闻网站的在线评论插件，运行于 2015 到 2017 年。¹ 该数据集包含 180 万条评论的文本内容，以及文章 ID 和时间戳等元数据，还有对每条评论内容和质量的众包评分。关键变量是 *Approval*，表示一条评论最初是否被其他评论者批准；以及 *Toxicity*，表示一条评论是否被至少一半人工标注者评为有毒。例如，一条写着 “Wow, that sounds great.” 的评论最初被批准，后来被 4 名标注者中的 0 名评为有毒 ($Approval = 1, Toxicity = 0$)。另一条写着 “haha you guys are a bunch of losers” 的评论最初被拒绝，并被 47 名标注者中的 42 名评为有毒 ($Approval = 0, Toxicity = 1$)。额外变量捕捉评论中最常被提及的人口身份。例如，一条写着 “The article says Sarah would be the first female candidate in THIS race|the 2016 one.” 的评论被 10 名标注者中的 8 名标记为提及女性 ($female = 1$)。身份提及相对稀疏，并且可用于包含约 400,000 条评论的子集。

Civil Comments 数据集包含机器学习数据的常见特征：数据集包含 180 万条评论；并且它是偏斜的，其中 8% 的评论被分类为有毒 ($Toxicity = 1$)，92% 的评论被分类为无毒 ($Toxicity = 0$)。最后，评论文本提供了允许机器学习使用的标准高维数据。

不同于典型的文本评论数据集，该数据集的独特之处在于我们观察到所有评论的“真实”标签。这使我们能够获得没有预测误差的真实估计，以便与依赖机器学习模型以不同误差程度预测标签的情形进行比较。这使我们能够评估由预测误差导致的问题程度，并检验校正方法的表现。

¹数据集及其文档可在 https://www.tensorflow.org/datasets/catalog/civil_comments 获得。

使用 Civil Comments 数据集，我们现在遵循两阶段模型来评估机器学习预测误差对因果推断的影响。在机器学习阶段，毒性估计由评论文本生成：

$$\widehat{Toxicity}_{it} = \hat{f}(Text_{it}) = Toxicity_{it} + \eta_{it} \quad (1)$$

在这一练习中，预测误差 η_{it} 可以被精确计算，因为我们观察每条评论的众包评分，并假设多数规则下的评分是正确的。因此，机器学习算法相对于作为真实标签的 $Toxicity$ 众包评分生成预测误差。在实践中，真实预测错误率未知，但可以使用训练数据上的交叉验证估计。从 180 万条评论中随机抽取 10% 作为我们的训练数据，其余 90% 是测试集，并删除真实 $Toxicity$ 值。为了模拟标准研究过程，我们使用带词嵌入的交叉验证卷积神经网络作为基准模型，该模型达到 94% 的预测准确率（模型的详细描述见附录 B）。这优于每次都猜测 $Toxicity = 0$ 可达到的 92% 基准准确率。

在因果推断阶段，我们的回归设定为

$$SevereToxicity_{it} = \hat{\beta} \widehat{Toxicity}_{it} + z_i + \tau_t + \tilde{\epsilon}_{it}. \quad (2)$$

感兴趣参数为 $\hat{\beta}$ ，即毒性对评论被标注为严重有毒的影响。类似标准经验模型，该设定包含评论所在文章的固定效应 z_i 和评论发布日期固定效应 τ_t 。我们可以观察原始毒性评分，因此还可以使用上述设定但用 $Toxicity_{it}$ 替代 $\widehat{Toxicity}_{it}$ ，从而估计不受第一阶段机器学习算法引入偏误影响的真实估计参数 β 。

补充说明：(Allon et al., 2023)一文中用的被解释变量为 $Toxicity_{it}$ ，但是我对于他们的估计结果有一些疑问，因此我将被解释变量替换成了 $SevereToxicity_{it}$ 。这个模型解释起来更简单，如果模型被标注为“有毒”那么它就更可能被标注为“严重有毒”。如果被解释变量为 $Approval_{it}$ ，效果会略有下降，不过结论依然成立。

6.2 本文实验设置

原始数据集约包含 180 万条观测。由于本节的主要目的在于验证本文所提出方法的有效性，而非在完整数据集上进行大规模预测建模，本文优先考虑计算效率与实验可重复性，从原始数据集中随机抽取 10% 作为实验样本。该实验样本约包含 18 万条观测，并进一步按照 8:2 的比例划分为训练集和测试集。其中，训练集，即 `dataset_role=train` 的样本，共包含 144,389 条观测，用于训练第一阶段机器学习模型；随后，将训练得到的模型应用于测试集，以生成测试集中对应的机器学习预测变量。测试集共包含 36,098 条观测。最终，训练得到的第一阶段模型在测试集上的预测准确率为 93.37%。

在二阶段估计中，本文仅使用测试集样本进行回归分析，因此可用于二阶段估计的样本量为 $n = 36,098$ 。在本节中，我们固定总验证预算为 $B = 3000$ ，并按照 1:4 的比例将其划分为 pilot validation 样本（既有验证集）和需要额外进行验证的样本两部分： $B_{pilot} = 600$ $B_{remain} = 2400$ 。在每次 Monte Carlo 重复中，参数污染预测模型只使用 pilot 阶段 600 个已验证样本进行监督训练。具体而言，先在 pilot 样本内部计算污染方

向分数，作为参数污染预测模型的训练标签；然后使用 pilot 样本的可观测特征 $\hat{X}_i$ 训练随机森林参数污染预测模型；最后将该模型应用于其余未验证样本的可观测特征 $\hat{X}_i$ ，用于生成第二阶段主动抽样概率。

本文比较朴素估计量、经典推断估计量、均匀矫正估计量以及主动验证估计量和 oracle estimator 之间的差异。其中，oracle estimator 指使用测试集中全部样本的真实变量 X_i 所得到的估计量；朴素估计量仅为使用机器学习生成的代理变量 $\hat{X}_i$ 进行估计；validation-only 方法仅使用 3000 个被验证样本及其真实 X_i 进行 OLS 估计；uniform corrected（均匀验证法）与 active corrected（主动验证法）则在全部 36,098 个测试样本上使用代理变量 $\hat{X}_i$ 构造校正矩条件，但只有 3000 个样本会额外观测到真实 X_i ，两个方法的差异在于验证样本概率的选择不同。因此，validation-only、uniform corrected 和 active corrected 三种方法在真实标签获取成本上保持一致；不同之处在于，后两种校正方法进一步利用了全样本中的代理变量信息，从而在相同验证预算下提高二阶段估计的精度。综上，我们三个基准，其一是朴素估计 (naive)，即只使用代理变量进行回归；其二是经典推断，均匀验证并且只用验证样本回归 (validation-only)；其三是均匀校正估计，即使用主动验证方法，但是验证概率被设置成均匀验证 (uniform corrected)。

实验参数设置如下：Monte Carlo 重复次数为 $R = 100$ 。本节将外部预测文件中 ‘dataset_role=validation’ 的 36,098 个样本作为回归分析总体。所有二阶段估计均吸收评论所在文章固定效应和评论发布日期固定效应。混合参数 τ 从候选集合 $\mathcal{T}_\tau = \{0, 0.05, 0.10, \dots, 0.50\}$ 中选择，网格间隔为 0.05。机器学习模型训练参数请见 (Allon et al., 2023) 附录。参数污染预测模型训练参数见文末附录。

oracle 估计量使用全部 36,098 个 validation 子样本上的真实 X_i 计算，得到 $\beta^{\text{oracle}} = 0.044140$ 。相应的 Monte Carlo 汇总结果如表 1 所示。

表 1: 仅使用 ‘dataset_role=validation’ 的 36,098 个样本时的 Monte Carlo 结果

方法	偏差 (bias)	标准差 (sd)	均方误差 (mse)	平均绝对误差 (mae)
朴素估计 (naive)	-0.013007	0.000000	0.000169	0.013007
仅验证样本估计 (validation-only)	-0.000400	0.004320	0.000019	0.003401
均匀校正估计 (uniform corrected)	0.000089	0.003642	0.000013	0.002877
主动校正估计 (active corrected)	-0.000062	0.003191	0.000010	0.002575

表 1 呈现出以下结论。第一，直接使用机器学习代理变量的朴素估计偏差非常明显，其平均偏差为 -0.013007，均方误差达到 0.000169，显著劣于其余三种方法。这说明即使机器学习预测准确率较高，一阶段预测误差对矩条件的污染仍然十分明显。第二，在固定总验证预算 $B = 3000$ 的条件下，两种校正方法都优于单纯只用验证样本做估计

的方法。validation-only 的标准差为 0.004320，而 uniform corrected 已经下降到 0.003642，下降幅度约为 15.69%。这说明即使只是均匀地分配验证样本，只要把全样本代理信息重新纳入估计，有限样本效率也会提升。第三，主动校正方法在这一设定下表现最好。与 uniform corrected 相比，active corrected 的均方误差从 0.000013 进一步下降到 0.000010，下降幅度约为 23.26%；平均绝对误差从 0.002877 下降到 0.002575，下降幅度约为 10.50%；标准差也从 0.003642 下降到 0.003191，下降幅度约为 12.39%。因此，在相同的真实标签预算下，主动设计验证样本确实能够更有效地控制校正项方差。

6.3 达到同等精度所需的验证样本节省（样本节省度分析）

上一节固定验证预算 $B = 3000$ ，比较了不同估计方法在相同真实标签成本下的有限样本表现。本节进一步从样本节省的角度评价主动验证方法：若传统方法在给定验证预算 B 下达到某一平均置信区间宽度，主动验证方法需要多少验证样本才能达到相同宽度？这一问题更直接地对应本文方法在实际标注成本上的含义。

具体而言，对每一个验证预算 B ，我们先计算仅验证样本估计、均匀校正估计和主动校正估计的平均 90% 置信区间宽度。记基准方法在预算 B 下的平均区间宽度为 $W_{\text{base}}(B)$ ，主动校正估计在预算 B' 下的平均区间宽度为 $W_{\text{act}}(B')$ 。如果存在两个相邻预算点 B_k 与 B_{k+1} ，使得

$$W_{\text{act}}(B_k) > W_{\text{base}}(B) > W_{\text{act}}(B_{k+1}),$$

则使用线性插值估计主动方法达到同等精度所需的预算：

$$B_{\text{act}}(B) = B_k + \frac{W_{\text{act}}(B_k) - W_{\text{base}}(B)}{W_{\text{act}}(B_k) - W_{\text{act}}(B_{k+1})}(B_{k+1} - B_k).$$

相应的样本节省比例定义为

$$\text{Saving}(B) = \frac{B - B_{\text{act}}(B)}{B} \times 100\%.$$

因此，若 $\text{Saving}(B) > 0$ ，表示主动验证方法用更少的真实标签即可达到基准方法在预算 B 下的平均区间宽度；若该数值为负，则说明在该预算区间内主动方法尚未体现出样本节省优势。

本节仍使用 dataset_role=validation 的 36,098 个样本作为回归分析总体。Monte Carlo 重复次数为 $R = 100$ ，预算网格设为

$$B \in \{500, 750, 1000, 1500, 2000, 2500, 3000, 4000, 5000, 5500, 6000, 6500, 7000, 10000\}.$$

对每一个预算点，主动方法均将总预算的 20% 用作 pilot 样本，其余预算用于第二阶段主动验证。

表 2: 不同验证预算下的平均 90% 置信区间宽度

验证预算 B	平均 90% 置信区间宽度			主动验证估计相对缩短比例	
	仅验证样本估计	均匀验证估计	主动验证估计	相对仅验证样本估计 (%)	相对均匀验证估计 (%)
500	0.034147	0.031022	0.031638	7.35	-1.99
750	0.028631	0.025921	0.025417	11.23	1.94
1000	0.025014	0.023116	0.022456	10.22	2.86
1500	0.021118	0.018739	0.017028	19.37	9.13
2000	0.018553	0.016207	0.014667	20.95	9.50
2500	0.016772	0.014595	0.013011	22.43	10.85
3000	0.015236	0.013341	0.011762	22.80	11.84
4000	0.013142	0.011620	0.010009	23.83	13.86
5000	0.011742	0.010375	0.008890	24.29	14.32
5500	0.011203	0.009938	0.008530	23.86	14.17
6000	0.010692	0.009483	0.008141	23.86	14.15
6500	0.010293	0.009146	0.007820	24.02	14.49
7000	0.009920	0.008794	0.007570	23.69	13.92
10000	0.008304	0.007441	0.006351	23.52	14.65

表 2 显示，主动校正方法在极小预算下相对于均匀校正方法仍然存在一定不稳定性。当 $B = 500$ 时，由于 pilot 样本过少，参数污染预测模型难以稳定学习矩污染较大的样本特征，主动校正估计的平均区间宽度为 0.031638，略高于均匀校正估计的 0.031022，对应的相对均匀校正估计缩短比例为负。但是从 $B = 750$ 开始，主动方法的平均区间宽度已经低于两个基准方法，其区间宽度为 0.025417，相比仅验证样本估计和均匀校正估计分别缩短 11.23% 和 1.94%。随着预算继续增加，主动方法的优势逐渐扩大并趋于稳定。例如，当 $B = 3000$ 时，主动校正估计的平均区间宽度为 0.011762，明显低于仅验证样本估计的 0.015236 和均匀校正估计的 0.013341，对应的相对缩短比例分别为 22.80% 和 11.84%。在更大的预算下，这一优势基本保持稳定，例如当 $B = 10000$ 时，主动校正估计的平均区间宽度进一步下降至 0.006351，相较于仅验证样本估计和均匀校正估计分别缩短 23.52% 和 14.65%。

表 3 报告了按照上述线性插值方法得到的样本节省比例。其中，“相对仅验证样本估计”表示主动方法达到仅验证样本估计在预算 B 下同等平均区间宽度所需节省的真实标签比例；“相对均匀校正估计”则表示主动方法相对于均匀校正估计的节省比例。

同样地，表 3 表明，主动验证方法并非在所有预算区间内都表现最优。在 $B = 500$ 时，主动方法相对于均匀校正估计的样本节省比例为负，这与本文前文的理论讨论一致：校正并不是无条件有益的，主动验证也需要足够的信息来估计出一个合理的验证概率。

不过，一旦预算稍有提升，主动验证方法开始带来显著的样本节省。当基准预算为 $B = 3000$ 时，仅验证样本估计需要 3000 个真实标签才能达到平均区间宽度 0.015236，而主动校正估计通过线性插值估计仅需约 1879 个真实标签即可达到同等宽度，对应节省 37.35%。相对于均匀校正估计，主动方法达到同等宽度所需预算约为 2400，对应节




图 1: 平均 90% 置信区间宽度随验证预算变化

表 3: 达到同等平均区间宽度所需的验证样本节省比例

预算 B	相对仅验证样本估计		相对均匀校正估计	
	主动所需预算	节省比例 (%)	主动所需预算	节省比例 (%)
500	500.00	0.00	524.77	-4.95
750	620.84	17.22	729.76	2.70
1000	784.08	21.59	944.26	5.57
1500	1123.25	25.12	1342.41	10.51
2000	1359.56	32.02	1673.87	16.31
2500	1554.09	37.84	2021.76	19.13
3000	1879.36	37.35	2400.16	19.99
4000	2460.48	38.49	3081.20	22.97
5000	3011.17	39.78	3791.19	24.18
5500	3318.79	39.66	4063.66	26.12
6000	3610.53	39.82	4470.32	25.49
6500	3838.03	40.95	4771.23	26.60
7000	4079.48	41.72	5133.27	26.67
10000	5790.55	42.09	7317.95	26.82

省 19.99%。在最大预算点 $B = 10000$ 下，主动验证方法相对于仅验证样本估计的节省比例达到 42.09%，相对于均匀校正估计的节省比例达到 26.82%。




图 2: 达到同等平均区间宽度时主动验证的样本节省比例

参考文献

- [1] Allon, Gad, Daniel Chen, Zhenling Jiang, and Dennis J. Zhang. 2023. Machine Learning and Prediction Errors in Causal Inference. The Wharton School Research Paper, forthcoming. Available at SSRN: <https://ssrn.com/abstract=4480696>.
- [2] Chen, Xiaohong, Han Hong, and Denis Nekipelov. 2011. Nonlinear Models of Measurement Errors. *Journal of Economic Literature* 49(4): 901–937.
- [3] Chen, Xiaohong, Han Hong, and Elie Tamer. 2005. Measurement Error Models with Auxiliary Data. *Review of Economic Studies* 72(2): 343–366.
- [4] Fong, Christian, and Matthew Tyler. 2020. Machine Learning Predictions as Regression Covariates. *Political Analysis* 29(4).
- [5] Fuller, Wayne A. 2009. *Measurement Error Models*. Hoboken, NJ: John Wiley & Sons.

- [6] Qiao, Mengke, and Ke-Wei Huang. 2021. Correcting Misclassification Bias in Regression Models with Variables Generated via Data Mining. *Information Systems Research* 32(2): 462–480.
- [7] Schennach, Susanne M. 2016. Recent Advances in the Measurement Error Literature. *Annual Review of Economics* 8: 341–377.
- [8] Wei, Max, and Nikhil Malik. 2026. Estimation Bias from Machine-Learned Features in Econometric Models. Working paper, University of Southern California.
- [9] Yang, Mochen, Gediminas Adomavicius, Gordon Burtch, and Yuqing Ren. 2018. Mind the Gap: Accounting for Measurement Error and Misclassification in Variables Generated via Data Mining. *Information Systems Research* 29(1): 4–24.
- [10] Zrnic, Tijana, and Emmanuel J. Candès. 2024. Active Statistical Inference. In *Proceedings of the 41st International Conference on Machine Learning*, PMLR 235: 62993–63010.

7 附录

参数污染预测模型是在既有验证样本（pilot 样本）上训练的，目标是预测这个样本对估计量污染大小 $s_{i,j} = a'_j d_i(\hat{\theta})$ 。训练目标设为： $\log(s_{i,j}^2 + c)$ ，其中 $s_{i,j}^2$ 会先做 98% 分位数上截尾， $c = \max(0.05 \times \text{median}(s_{i,j}^2), 10^{-6})$ 。这样做是为了减少极端 IPW 目标对随机森林的影响。训练参数设置如下：

```
RandomForestRegressor(
    n_estimators=400,
    random_state=seed,
    max_depth=8,
    min_samples_leaf=50,
    max_features="sqrt",
    n_jobs=-1,
    bootstrap=True,
    oob_score=True,
)
```

输入特征 $\hat{X}_i$ 只用验证前可见变量。当前这版实验里主要包括控制变量和代理预测值 $\hat{X}_i$ 。训练完以后，模型输出的是 $\log(\widehat{s_{i,j}^2} + c)$ ，再转回风险尺度： $\hat{h}_i = \exp(\hat{m}_i) - c$ 。然后主动抽样强度用： $u_i = \sqrt{\hat{h}_i}$ 。